

Esquema de Datos MapReduce

Contratos de datos del sistema de análisis de riesgo en contratación pública

DistributedProcessing, Documento 03-esquema-datos

Este documento define los contratos y estructuras de datos para las diferentes fases del ciclo de vida de procesamiento distribuido MapReduce en dos etapas: la Etapa 1 de agregación independiente por conjunto de datos, y la Etapa 2 de join distribuido sobre los resultados consolidados.

1. Etapa 1: Entrada de Map por conjunto de datos

1.1. Estructura del chunk para Procesos de Contratación

Cada Worker recibe un fragmento del conjunto de Procesos de Contratación de SECOP II.

Campo	Tipo	Descripción
chunk_id	string	Identificador único del bloque, por ejemplo process_chunk_001
source_dataset	string	Identifica Procesos de Contratación como origen
id_del_proceso	string	Identificador del proceso de compra en SECOP II
nit_entidad	string	NIT de la entidad que publicó el proceso
proveedores_invitados	uint32	Número de proveedores invitados a participar
proveedores_unicos_con_respuestas	uint32	Proveedores únicos que presentaron respuesta
modalidad_de_contratacion	string	Modalidad de selección del proceso
estado_del_procedimiento	string	Estado actual del proceso

1.2. Estructura del chunk para Contratos Electrónicos

Cada Worker recibe un fragmento del conjunto de Contratos Electrónicos de SECOP II.

Campo	Tipo	Descripción
chunk_id	string	Identificador único del bloque, por ejemplo contract_chunk_001
source_dataset	string	Identifica Contratos Electrónicos como origen
proceso_de_compra	string	Identificador del proceso asociado a este contrato
nit_entidad	string	NIT de la entidad contratante

Campo	Tipo	Descripción
documento_proveedor	string	NIT o cédula del proveedor adjudicado
proveedor_adjudicado	string	Nombre del proveedor adjudicado
valor_del_contrato	uint64	Valor total del contrato en pesos
codigo_de_categoria_principal	string	Código UNSPSC de la categoría del bien/servicio
modalidad_de_contratacion	string	Modalidad de contratación utilizada
fecha_de_firma	string	Fecha de firma del contrato

2. Etapa 1: Salida de Map

La función Map de cada Job emite pares clave-valor intermedios según el conjunto procesado.

2.1. Output del Job A: Índice de competencia por proceso

Para cada proceso, calcula y emite el índice de competencia real.

Componente	Tipo	Descripción
Clave	string	id_del_proceso
Valor tipo	CompetitionMetrics	Estructura con índice de competencia

Estructura CompetitionMetrics:

Campo	Tipo	Descripción
id_del_proceso	string	Identificador del proceso
nit_entidad	string	NIT de la entidad
proveedores_invitados	uint32	Número de proveedores invitados
proveedores_responden	uint32	Número de proveedores que respondieron
indice_competencia	float32	Razón entre responden e invitados
modalidad_de_contratacion	string	Modalidad del proceso

2.2. Output del Job B: dos reduces independientes sobre Contratos Electrónicos

El Job B calcula dos métricas de naturaleza distinta que requieren dos claves de agrupación diferentes, y por tanto se implementan como dos reduces separados dentro del mismo Job, no como uno solo. La desviación de precio es una propiedad de un contrato individual frente a su categoría; la concentración proveedor-entidad es una propiedad agregada de todos los contratos de un proveedor con una entidad, y no puede calcularse correctamente agrupando por proceso.

2.2.1. Reduce B1: desviación de precio, agrupado por categoría

La fase Map emite pares con clave categoria_unspsc y valor el contrato individual. El shuffle agrupa todos los contratos de la misma categoría en el mismo worker. El Reduce calcula la mediana de valor_del_contrato dentro de esa categoría y produce, por cada contrato, su desviación respecto a esa mediana.

Componente	Tipo	Descripción
Clave	string	codigo_de_categoria_principal
Valor tipo	ContractPriceMetrics	Estructura con desviación de precio por contrato

Estructura ContractPriceMetrics:

Campo	Tipo	Descripción
proceso_de_compra	string	Identificador del proceso asociado
nit_entidad	string	NIT de la entidad contratante
documento_proveedor	string	NIT del proveedor adjudicado
valor_del_contrato	uint64	Valor del contrato en pesos
categoria_unspsc	string	Código de categoría UNSPSC
mediana_categoria	uint64	Mediana de valor en la categoría
desviacion_precio	float32	Desviación respecto a la mediana de categoría

2.2.2. Reduce B2: concentración proveedor-entidad, agrupado por relación

La fase Map emite pares con clave compuesta documento_proveedor más nit_entidad, y valor el contrato individual. El shuffle agrupa todos los contratos de un mismo proveedor con una misma entidad en el mismo worker. El Reduce cuenta el total de contratos de ese proveedor en todas las entidades, el total de contratos de ese proveedor con esa entidad específica, y calcula el porcentaje de concentración.

Componente	Tipo	Descripción
Clave	string	documento_proveedor + nit_entidad
Valor tipo	ProviderConcentration	Estructura con concentración por relación

Estructura ProviderConcentration:

Campo	Tipo	Descripción
documento_proveedor	string	NIT del proveedor
nit_entidad	string	NIT de la entidad
contratos_con_entidad	uint32	Contratos de este proveedor con esta entidad

Campo	Tipo	Descripción
contratos_totales_proveedor	uint32	Contratos totales del proveedor en todas las entidades
concentracion_proveedor	float32	Razón entre contratos_con_entidad y contratos_totales_proveedor

El resultado de B2 se une de vuelta a nivel de proceso en la Etapa 2, junto con el resultado de B1, ya que ambos comparten documento_proveedor y nit_entidad como llave de referencia hacia cada proceso individual.

3. Etapa 1: Reduce

El Reduce consolida las salidas intermedias por clave.

3.1. Reduce del Job A

Recibe todas las CompetitionMetrics agrupadas por id_del_proceso y produce un registro por proceso.

3.2. Reduce B1 del Job B

Recibe todas las ContractPriceMetrics agrupadas por categoria_unspsc, calcula la mediana de la categoría, y produce un registro por contrato con su desviación de precio.

3.3. Reduce B2 del Job B

Recibe todos los contratos agrupados por documento_proveedor más nit_entidad y produce un registro por relación proveedor-entidad con su índice de concentración.

4. Etapa 2: Join distribuido

El reduce-side join une los resultados consolidados de los tres reduces de la Etapa 1 sobre la clave id_del_proceso, siguiendo el patrón de etiquetado por origen.

4.1. Mecánica del join

La fase Map de la Etapa 2 lee las tres tablas intermedias producidas en la Etapa 1 y etiqueta cada registro según su origen antes de emitirlo, produciendo pares con clave id_del_proceso y valor una tupla de origen más datos.

Origen	Tabla fuente	Contenido emitido
A	Reduce Job A	CompetitionMetrics, con id_del_proceso como clave directa
B1	Reduce B1	ContractPriceMetrics, con proceso_de_compra como clave
B2	Reduce B2	ProviderConcentration, referenciado por proceso a través de documento_proveedor y nit_entidad presentes en el registro B1 correspondiente

El shuffle agrupa por `id_del_proceso`, de forma que todos los registros etiquetados A, B1 y B2 correspondientes al mismo proceso llegan al mismo worker de Reduce. El Reduce separa los valores recibidos según su etiqueta de origen y combina los tres en un único registro de salida.

Se maneja explícitamente el caso de un proceso presente en la tabla A pero sin registro correspondiente en B1 o B2, correspondiente a un proceso no adjudicado o desierto, como un left outer join: dicho registro se conserva en la salida con los campos de contrato marcados como no disponibles, en lugar de descartarse, ya que constituye un hallazgo propio de interés para el análisis de riesgo.

4.2. Entrada del Join

Tabla intermedia A: CompetitionMetrics por proceso, resultado del Reduce Job A.

Tabla intermedia B1: ContractPriceMetrics por contrato, resultado del Reduce B1.

Tabla intermedia B2: ProviderConcentration por relación proveedor-entidad, resultado del Reduce B2.

Clave de unión principal: `id_del_proceso` en Tabla A equivalente a `proceso_de_compra` en Tabla B1. La Tabla B2 se referencia a través de la pareja `documento_proveedor` y `nit_entidad` presente en cada registro de B1.

4.3. Salida del Join: Indicador de Riesgo Consolidado

Los campos relativos al contrato son opcionales y solo se completan cuando existe un registro correspondiente en la Tabla B1, según lo descrito para el left outer join. Un proceso sin contrato asociado conserva sus campos de competencia y se marca mediante `tiene_contrato` en falso.

Campo	Tipo	Descripción
<code>id_del_proceso</code>	string	Identificador único del proceso
<code>nit_entidad</code>	string	NIT de la entidad
<code>indice_competencia</code>	float32	Índice de competencia real del proceso
<code>estado_del_procedimiento</code>	string	Estado del proceso, relevante cuando no hay contrato
<code>tiene_contrato</code>	bool	Indica si el proceso tiene un contrato adjudicado asociado
<code>documento_proveedor</code>	string	NIT del proveedor ganador, vacío si <code>tiene_contrato</code> es falso
<code>desviacion_precio</code>	float32	Desviación de precio respecto a categoría, si aplica
<code>concentracion_proveedor</code>	float32	Concentración del proveedor con entidad, si aplica
<code>puntuacion_riesgo</code>	float32	Puntuación combinada de riesgo
<code>flag_riesgo_alto</code>	bool	Indicador si la combinación supera umbral de riesgo

5. Salida Final: Reporte de Resultados

El Master consolida los registros de riesgo y genera un reporte ordenado.

Campo	Tipo	Descripción
job_id	string	Identificador del trabajo de análisis
execution_time_ms	uint64	Tiempo total de cómputo en milisegundos
total_procesos_analizados	uint64	Cantidad de procesos procesados
total_procesos_alto_riesgo	uint64	Procesos que superan umbral de riesgo
registros_riesgo	list<RiskRecord>	Lista de procesos de riesgo ordenados por puntuación

Estructura RiskRecord:

Campo	Tipo	Descripción
id_del_proceso	string	Identificador del proceso
nit_entidad	string	NIT de la entidad
nombre_entidad	string	Nombre de la entidad
tiene_contrato	bool	Si el proceso tiene contrato adjudicado asociado
documento_proveedor	string	NIT del proveedor, vacío si no tiene contrato
nombre_proveedor	string	Nombre del proveedor
valor_contrato	uint64	Valor del contrato
indice_competencia	float32	Índice de competencia observado
desviacion_precio	float32	Desviación de precio
concentracion	float32	Concentración del proveedor con entidad
puntuacion_riesgo	float32	Puntuación final de riesgo combinada
flag_riesgo_alto	bool	Indicador si la combinación supera umbral de riesgo

6. Especificación de contratos para gRPC / Protocol Buffers

Los contratos conceptuales anteriores se mapean a la siguiente definición formal en Protocol Buffers v3.

```

syntax = "proto3";

package secopanalysis;

option go_package = "./proto";

message ProcessDataChunk {

```

```

    string chunk_id = 1;
    string id_del_proceso = 2;
    string nit_entidad = 3;
    uint32 proveedores_invitados = 4;
    uint32 proveedores_unicos_con_respuestas = 5;
    string modalidad_de_contratacion = 6;
    string estado_del_procedimiento = 7;
}

message ContractDataChunk {
    string chunk_id = 1;
    string proceso_de_compra = 2;
    string nit_entidad = 3;
    string documento_proveedor = 4;
    string proveedor_adjudicado = 5;
    uint64 valor_del_contrato = 6;
    string codigo_de_categoria_principal = 7;
    string fecha_de_firma = 8;
}

message CompetitionMetrics {
    string id_del_proceso = 1;
    string nit_entidad = 2;
    uint32 proveedores_invitados = 3;
    uint32 proveedores_responden = 4;
    float indice_competencia = 5;
    string modalidad_de_contratacion = 6;
    string estado_del_procedimiento = 7;
}

// Reduce B1: desviación de precio, agrupado por categoría UNSPSC
message ContractPriceMetrics {
    string proceso_de_compra = 1;
    string nit_entidad = 2;
    string documento_proveedor = 3;
    uint64 valor_del_contrato = 4;
    string categoria_unspsc = 5;
    uint64 mediana_categoria = 6;
    float desviacion_precio = 7;
}

// Reduce B2: concentración, agrupado por documento_proveedor + nit_entidad
message ProviderConcentration {
    string documento_proveedor = 1;
    string nit_entidad = 2;
    uint32 contratos_con_entidad = 3;
    uint32 contratos_totales_proveedor = 4;
    float concentracion_proveedor = 5;
}

message RiskRecord {
    string id_del_proceso = 1;

```

```

string nit_entidad = 2;
string nombre_entidad = 3;
bool tiene_contrato = 4;
string documento_proveedor = 5;
string nombre_proveedor = 6;
uint64 valor_contrato = 7;
float indice_competencia = 8;
float desviacion_precio = 9;
float concentracion = 10;
float puntuacion_riesgo = 11;
bool flag_riesgo_alto = 12;
}

message RiskAnalysisResult {
    string job_id = 1;
    uint64 execution_time_ms = 2;
    uint64 total_procesos_analizados = 3;
    uint64 total_procesos_alto_riesgo = 4;
    repeated RiskRecord registros_riesgo = 5;
}

```

6.1. Aclaraciones de campos

La directiva repeated de Protocol Buffers serializa listas dinámicas de forma binaria eficiente, sin delimitadores de texto. Los enteros para valores monetarios y conteos se mapearon a uint64, mientras que los índices y proporciones se mapearon a float32 para balance entre precisión y tamaño. El job_id actúa como identificador global para indexar y almacenar los resultados de forma única.